

RESUMO DE ESTUDO

Inteligência Artificial

Fundamentos · IA generativa · modelos · ética · agentes · prompts

Disciplina Informática

Assunto Inteligência Artificial

Aula Aula 14

Edição Setembro de 2026

INTELIGÊNCIA ARTIFICIAL

Fundamentos · IA generativa · riscos · agentes · engenharia de prompt

1. Fundamentos e fronteiras da inteligência artificial

Inteligência Artificial (IA) é o campo que desenvolve sistemas capazes de executar tarefas associadas à cognição humana. Esses sistemas simulam processos como aprendizagem, raciocínio e autocorreção para perceber dados, reconhecer padrões, decidir ou resolver problemas. Podem aprender com dados, adaptar comportamentos, agir com autonomia configurada e interagir por linguagem, imagens ou sensores. Isso não significa que toda IA possua consciência, compreensão genuína ou aprendizagem contínua.

A IA é o campo mais amplo. Machine learning é o subcampo em que algoritmos extraem padrões da experiência e dos dados; deep learning emprega redes neurais profundas com várias camadas para aprender representações complexas. Processamento de Linguagem Natural (PLN) compreende e gera linguagem; visão computacional interpreta imagens e cenas; robótica integra percepção, decisão e ação física. A IA também inclui regras, lógica e otimização: é falso limitar todo aprendizado ao reconhecimento de textos e imagens.

CONCEITO	REGRA ESSENCIAL
Teste de Turing	Avalia se, em conversa, o comportamento da máquina pode ser indistinguível do humano; não comprova consciência.
Aprendizagem	Mudança de desempenho ou comportamento com dados e experiência; não é sinônimo de autonomia.
Autonomia	Capacidade de agir sem intervenção humana contínua, dentro da configuração e dos limites do sistema.
Computação cognitiva	Subcampo voltado a raciocínio e compreensão de alto nível análogos à cognição, lógica e julgamento humanos.

IA × MACHINE LEARNING

Machine learning é subárea da IA. Sistemas de IA não dependem necessariamente de algoritmos simples e fixos, mas nem todo sistema precisa aprender continuamente ou agir de modo autônomo.

1.1 Ontologias e conhecimento

Ontologia é uma representação formal e estruturada do conhecimento de um domínio: define conceitos, categorias, propriedades, relações e restrições, formando um vocabulário comum processável por máquinas e compreensível por pessoas. Um banco de dados organiza como os dados são armazenados; a ontologia explicita o que eles significam e como se relacionam. Ela apoia integração de fontes heterogêneas, IA simbólica, inferência, interoperabilidade e explicabilidade.

Representações formais, como RDF ou OWL, permitem consumo computacional; representações gráficas facilitam a compreensão humana. Ontologia não é sistema especialista: este sim procura aplicar regras e conhecimento para simular a atuação de especialistas em problemas de um domínio.

2. Tipos de IA e paradigmas de aprendizagem

CLASSIFICAÇÃO	ESCOPO E STATUS
IA fraca / estreita	Realidade atual: executa tarefas específicas com eficiência, sem consciência, compreensão genuína ou generalização ampla.
IA forte	Hipótese de sistema com consciência, compreensão real, raciocínio geral e transferência de conhecimento entre domínios.
ANI	Artificial Narrow Intelligence: especialização em um domínio; não evolui naturalmente para AGI sem intervenção humana.

CLASSIFICAÇÃO	ESCOPO E STATUS
AGI	Artificial General Intelligence: capacidade geral comparável à humana para aprender e resolver problemas diversos; ainda teórica.
ASI	Artificial Superintelligence: superaria amplamente capacidades humanas; conceito hipotético com riscos éticos e existenciais.

A IA fraca pode superar pessoas em tarefas bem delimitadas, como reconhecimento de padrões, sem adquirir inteligência geral. Chatbots, recomendadores, reconhecimento de voz e diagnóstico assistido continuam estreitos. Criatividade, bom senso, consciência e compreensão contextual não decorrem automaticamente de desempenho estatístico.

APRENDIZADO	COMO FUNCIONA
Supervisionado	Treina com pares entrada-saída rotulados; classificação prevê categorias e regressão prevê valores.
Não supervisionado	Descobre agrupamentos, estruturas latentes e anomalias em dados sem rótulos; é relevante no pré-treinamento.
Por reforço	Um agente interage com o ambiente, recebe recompensas ou penalidades e ajusta sua política para maximizar retorno cumulativo.

TROCAS TÍPICAS

Reforço não é classificação com rótulos prévios. Autonomia é agir sem intervenção contínua; aprendizagem é alterar o comportamento com experiência. ANI não se converte espontaneamente em AGI.

3. IA generativa: conceito, ciclo e modelos de base

IA generativa reúne técnicas destinadas a criar conteúdo novo — texto, imagem, áudio, vídeo, código e dados sintéticos — a partir de padrões aprendidos. Diferentemente de um classificador, ela modela regularidades para produzir novas amostras. A saída é probabilística: não é simples consulta a banco de respostas nem cópia literal, e o mesmo prompt pode gerar resultados diferentes.

O ciclo começa com coleta, limpeza e organização dos dados. O treinamento ajusta milhões ou bilhões de parâmetros; fine-tuning e alinhamento adaptam tarefas e comportamentos. Na implantação, inferência é a geração efetiva a partir da entrada. Monitoramento, correção, atualização ou novo treinamento tratam desempenho e riscos em uso real.

Modelos de base (foundation models) são redes de grande escala pré-treinadas em dados variados. A base generalista pode ser reutilizada e ajustada para muitas tarefas sem reconstrução completa.

Multimodalidade é a capacidade de processar e relacionar texto, imagem, áudio, vídeo ou código e de produzir saídas em formatos diversos; modelos multimodais podem projetar essas modalidades em espaços vetoriais relacionados e empregar atenção cruzada.

MODELO	DISTINÇÃO DECISIVA
Discriminativo	Aprende fronteira ou $P(Y X)$: separa, classifica ou prevê a saída dada a entrada, sem precisar modelar como os dados surgem.
Generativo	Aprende estrutura ou distribuição conjunta $P(X,Y)$: cria novas amostras semelhantes às observadas e também pode apoiar classificação.
Modelo de base	Pré-treinado em larga escala e reutilizável por prompt ou ajuste fino em tarefas variadas.
Multimodal	Integra representações de modalidades distintas, em vez de tratar apenas texto isolado.

CEBRASPE

IA generativa não é prioritariamente e exclusivamente supervisionada. Ela pode empregar pré-treinamento auto/não supervisionado, supervisão e reforço em fases distintas.

4. Modelos de linguagem, tokens e Transformers

Modelos de linguagem aprendem padrões sintáticos, semânticos e contextuais em grandes corpora para compreender, produzir e manipular linguagem. Eles não são treinados exclusivamente por regras sintáticas explícitas nem apenas com dados anotados manualmente. Um Large Language Model (LLM) é uma rede neural de deep learning pré-treinada em grandes volumes textuais, capaz de reconhecer, traduzir, prever e gerar linguagem e executar outras tarefas de PLN.

Tokenização divide o texto em unidades menores, os tokens. Embeddings convertem tokens em vetores; no espaço latente, características abstratas e relações semânticas são codificadas, de modo que conceitos próximos ocupem regiões relacionadas. Um LLM autorregressivo gera token por token, calculando o próximo elemento com base no contexto anterior. Fluência resulta de probabilidade, não de consciência ou garantia de verdade.

A arquitetura Transformer elimina recorrência e usa atenção para ponderar quais partes da sequência são relevantes, inclusive a longa distância, permitindo processamento paralelo e manutenção de contexto. GPT significa Generative Pre-trained Transformer. O destaque recente dos LLMs combina melhor treinamento com feedback humano, interfaces acessíveis, maior potência de GPUs e dados mais amplos e melhores.

ARQUITETURA	TRAÇO CENTRAL
Feed-forward / MLP	Fluxo da entrada à saída sem ciclos; classificação e regressão em padrões mais simples.
CNN	Convolução e pooling extraem padrões locais em grades, especialmente imagens.
RNN	Estado recorrente preserva informação temporal em sequências; LSTM e GRU lidam melhor com dependências longas.
Transformer	Atenção processa relações em paralelo e sustenta GPT, BERT e modelos modernos de linguagem.

Reconhecimento de voz não transforma áudio bruto diretamente em texto sem mediação: extrai características e usa modelos acústicos, linguísticos ou redes neurais para mapear sinais em unidades e frases coerentes.

GPT E LLM

GPT não significa “gerador de processamento de texto”. LLM é o modelo de linguagem em larga escala; ChatGPT é uma aplicação conversacional baseada nesse tipo de modelo.

5. Modelos generativos clássicos e difusão

MODELO	MECANISMO E RISCO
GAN	Geradora cria amostras sintéticas; discriminadora distingue reais e geradas. O jogo min–max melhora ambas; colapso de modo reduz a variedade produzida.
VAE	Encoder aprende média e variância de uma distribuição latente; decoder reconstrói e gera. A regularização ocorre durante o treinamento, não apenas depois.
Difusão	O processo direto adiciona ruído; o reverso aprende a removê-lo gradualmente e gera dados a partir de ruído. É geração, não classificação.
Modelos de imagem/áudio/vídeo	Aprendem padrões visuais, sonoros ou espaço-temporais para síntese, edição, restauração e simulação probabilística.

GANs podem sustentar deepfakes porque duas redes competem: uma falsifica e a outra avalia autenticidade. VAEs oferecem espaço latente probabilístico contínuo e geração por amostragem, sem garantia de “maior dimensão”. Modelos de difusão costumam ser estáveis e detalhados, porém iterativos e mais lentos que uma geração em etapa única.

6. Agentes, assistentes e sistemas conversacionais

Agente de IA é entidade capaz de perceber o ambiente por sensores ou entradas digitais, decidir com base nas percepções e agir por atuadores ou interfaces para atingir objetivos. Agente racional escolhe, para cada situação, a ação que maximiza o desempenho esperado, considerando conhecimento disponível, limitações e metas. Percepção capta e interpreta; ação provoca mudanças no ambiente.

Agentes modernos podem combinar persona, memória de curto ou longo prazo, ferramentas externas e um modelo de linguagem. O modelo interpreta e planeja; ferramentas consultam bancos, APIs ou sistemas e executam ações. Assistente é orientado a apoiar o usuário sob comando ou supervisão. Bot tradicional costuma seguir fluxos mais restritos e previsíveis, embora possa receber um LLM.

TIPO DE AGENTE	DECISÃO
Reativo	Usa somente a percepção atual e regras se-então; não mantém memória ou modelo interno.
Baseado em modelo	Mantém estado interno e histórico para inferir partes não observadas do ambiente.
Baseado em objetivo	Avalia estados futuros e escolhe ações que aproximem a meta.
Baseado em utilidade	Compara alternativas por uma função numérica e maximiza satisfação ou benefício esperado.
De aprendizado	Ajusta comportamento com experiência, dados, recompensa ou feedback.
Deliberativo / híbrido	Planeja explicitamente / combina reação rápida e planejamento.
Multiagente	Coopera ou compete com outros agentes por comunicação, coordenação e negociação.

ChatGPT é assistente baseado em Transformer, capaz de manter contexto, gerar texto e código e, em versões recentes, processar diferentes modalidades; respostas convincentes ainda podem alucinar. RLHF — aprendizado por reforço com feedback humano — ajusta o comportamento segundo clareza, utilidade e segurança, mas não confere consciência. Copilot integra assistência ao Microsoft 365; Gemini integra uma família multimodal ao ecossistema Google; DALL·E gera e edita imagens a partir de texto.

7. Engenharia de prompt e recuperação de informação

Engenharia de prompt é a prática de criar e ajustar instruções estrategicamente, sem retrainar o modelo, para orientar respostas mais precisas, úteis e relevantes. Bons prompts explicitam objetivo, contexto, papel ou persona, dados disponíveis, público, formato, extensão, critérios e restrições. Especificidade reduz ambiguidade, mas não garante exatidão.

TÉCNICA	REGRA
Zero-shot	Pede a tarefa sem exemplos.
Few-shot	Fornece poucos exemplos no prompt para demonstrar padrão, formato ou estilo.
Chain-of-Thought	Orienta etapas intermediárias de raciocínio; zero-shot CoT pede essas etapas sem fornecer exemplos.
Prompt chaining	Divide uma tarefa e usa a saída de cada prompt como entrada da etapa seguinte.
Self-consistency	Compara soluções independentes e seleciona a conclusão mais consistente.
Tree of Thoughts	Explora e avalia caminhos alternativos antes de escolher a estratégia.
ReAct	Combina raciocínio e ações, consultando ferramentas, documentos, APIs ou bases.
Self-critique	Revisa a própria resposta, identifica falhas e produz versão corrigida.

TÉCNICA	REGRA
Constraint-based	Impõe limites explícitos de conteúdo, formato ou estilo.

Retrieval-Augmented Generation (RAG) recupera trechos contextuais relevantes de uma fonte externa e os integra à entrada do modelo. O LLM não acessa dinamicamente fontes “sozinho”: precisa de mecanismo de busca, banco ou índice vetorial. O contexto recuperado tende a reduzir alucinações e melhorar fundamentação, mas a qualidade da fonte, da recuperação e da síntese ainda exige validação.

PROMPT × FINE-TUNING × RAG

Prompt orienta sem alterar parâmetros; fine-tuning retreina ou ajusta parâmetros com dados específicos; RAG acrescenta contexto recuperado em tempo de uso.

8. Riscos: desinformação, direitos, vieses e alucinações

IA generativa pode criar textos, imagens, vozes e vídeos falsos altamente verossímeis e disseminá-los em escala. Deepfakes favorecem fraude, manipulação política e dano reputacional. Marcas d’água, educação midiática, rastreabilidade, regulação e checagem mitigam o risco. IA pode ajudar a moderar conteúdo, mas não garante verdade nem elimina o julgamento humano.

Modelos podem ser treinados com obras protegidas sem consentimento ou compensação e produzir conteúdo muito semelhante, gerando controvérsia autoral. Licenciamento, opt-out e rastreamento são respostas propostas. Imagem, voz e identidade também são direitos da personalidade: clonagem e avatares sem base adequada podem violar a pessoa e a proteção de dados, ainda que não copiem uma obra.

VIÉS	ORIGEM OU EFEITO
Dados / amostragem	Conjunto não representa a realidade / proporções dos grupos são inadequadas.
Rotulagem / histórico	Rótulos incorporam preconceitos / padrões passados reproduzem desigualdades.
Algorítmico / exclusão	Estrutura e pesos amplificam distorções / grupos, contextos ou dados são omitidos.
Confirmação / seleção	Reforça crenças anteriores / escolhe dados por critérios enviesados.
Interpretação	O humano aceita o resultado sem examinar método, contexto ou limitações.

Treinar com dados numerosos ou aparentemente confiáveis não garante imparcialidade. Modelos podem reproduzir ou amplificar racismo, sexismo e sub-representação. Mitigação exige curadoria, amostragem diversa, auditorias, métricas de equidade, equipes plurais, transparência e revisão contextual.

Alucinação é informação falsa ou inexistente apresentada com confiança e aparência legítima. Ela decorre da previsão estatística sem acesso intrínseco à verdade. O corte de treinamento também gera desatualização; integrar busca em tempo real ajuda, mas pode combinar dados atuais com inferência errada. A saída é apoio, não fonte autônoma de verdade.

9. IA Responsável, proteção de dados e controle humano

A matriz FAT sintetiza Fairness, Accountability e Transparency: justiça e tratamento equitativo; responsabilização e prestação de contas; transparência sobre critérios, dados, métodos, capacidades e limitações. IA Responsável amplia o foco para impactos éticos, sociais e ambientais durante todo o ciclo de vida. IA Explicável concentra-se em tornar decisões e previsões compreensíveis.

PRINCÍPIO	EXIGÊNCIA
Transparência	Comunicar propósito, capacidades, limitações, riscos e que a interação ocorre com IA.
Explicabilidade / interpretabilidade	Explicar como e por que a saída surgiu / relacionar entradas, parâmetros e previsões.

PRINCÍPIO	EXIGÊNCIA
Privacidade / segurança	Proteger dados em projeto, preparação, treinamento, testes e implantação, com acesso e criptografia adequados.
Accountability	Registrar, auditar e atribuir responsabilidade por decisões, danos e impactos.
Inclusividade / diversidade	Garantir acesso e participação de grupos variados no desenho e teste.
Justiça / equidade	Evitar discriminação e resultados desiguais; relaciona-se à inclusão, mas não é sinônimo.
Confiabilidade / uso seguro	Manter desempenho consistente / prevenir danos mesmo em cenários inesperados.

Performance é desejável, mas não substitui esses princípios. Dados pessoais ou sensíveis não devem ser inseridos imprudentemente. Anonimização ou pseudonimização protege titulares, ainda que exija adaptação do uso. Pela LGPD, o tratamento demanda base jurídica válida, finalidade, transparência, segurança e prestação de contas; consentimento é uma das bases previstas — ao lado de contrato, obrigação legal e legítimo interesse — e não vale se genérico.

Human-in-the-loop exige validação humana para a decisão final; human-on-the-loop permite operação autônoma sob vigilância e possibilidade de intervenção. O usuário deve verificar coerência e precisão, editar a saída para o objetivo e validar conformidade ética, legal e técnica. Painéis de explicabilidade, alertas de confiança, logs, revisão colaborativa e políticas de uso sustentam esse controle.

ABSOLUTOS SUSPEITOS

Grande volume não “neutraliza” vieses; personalização não garante privacidade; IA não garante segurança, imparcialidade ou verdade; automação não elimina responsabilidade profissional.

10. Aplicações e limites profissionais

No trabalho, IA automatiza tarefas repetitivas, produz minutas, analisa volumes, detecta anomalias e prevê tendências. Ela aumenta eficiência, mas contexto, decisão estratégica e responsabilidade permanecem humanos. Personalização pode adaptar conteúdo sem garantir ética ou segurança dos dados.

ÁREA	USO E LIMITE
Auditoria	Analisa anomalias e redige minutas; registre ferramenta, configuração, dados, método, limitações e evidências.
Segurança	Detecta padrões; atacantes também usam phishing, deepfakes e malware adaptativo, exigindo analistas humanos.
Jornalismo	Acelera produção e checagem, mas não garante verdade ou compromisso ético.
Direito	Pesquisa e estima padrões; pode reproduzir vieses e não substitui fundamentação ou julgamento moral.
Setor público	Classifica processos e apoia serviços; exige transparência, proteção de dados e revisão.

Sub-representação no treinamento pode distorcer auditorias; conteúdo jornalístico rápido pode ser falso; previsão judicial histórica pode reproduzir preconceitos. Em toda área, alguém deve validar, documentar e responder pelo resultado.

REVISÃO DE ALTO RENDIMENTO

GATILHO	RESPOSTA DE PROVA
IA > ML > deep learning	IA é o campo; ML aprende com dados; deep learning usa redes profundas.
Fraca / forte	Tarefa específica sem consciência / inteligência geral consciente, ainda hipotética.
ANI / AGI / ASI	estreita / geral humana / superior à humana.
Ontologia	conceitos + propriedades + relações de um domínio; não é sistema especialista.
Generativa / discriminativa	gera por distribuição conjunta / classifica por fronteira ou $P(Y X)$.
Supervisionado / não supervisionado / reforço	rótulos / padrões sem rótulos / recompensa no ambiente.
LLM	deep learning + grande corpus + previsão de tokens; sem compreensão garantida.
Transformer	atenção, paralelismo e dependências longas.
GAN / VAE / difusão	geradora×discriminadora / latente probabilístico / remover ruído.
Agente racional	sensores → decisão que maximiza desempenho → atuadores.
Prompt / fine-tuning / RAG	instrução / ajuste de parâmetros / contexto externo recuperado.
PEGADINHA	CORREÇÃO
GPT	Generative Pre-trained Transformer.
Alucinação	falsidade convincente; fluência não é veracidade.
RAG	exige recuperação integrada; o LLM não acessa fonte externa sozinho.
VAE	regularização do latente ocorre durante o treinamento.
Difusão	é modelo generativo por ruído e denoising, não classificador.
Autonomia × aprendizagem	agir sem intervenção contínua × mudar com experiência.
Percepção × ação	captar ambiente × alterá-lo.
FAT	Fairness · Accountability · Transparency.
Human-in/on-the-loop	decisão validada pelo humano / autonomia sob vigilância.
Vieses	dados numerosos e automação não asseguram neutralidade.

PROMPTS: zero-shot = sem exemplos; few-shot = poucos exemplos; CoT = raciocínio em etapas; chaining = saídas encadeadas; self-consistency = comparar soluções; ReAct = raciocinar e usar ferramentas.

Contexto, formato e restrições orientam, mas não garantem acerto.

MODELOS: tokens viram embeddings; LLM autorregressivo prevê o próximo token. CNN trata padrões visuais; RNN, sequências; Transformer, atenção. Multimodal integra texto, imagem, áudio, vídeo ou código.

RISCOS: deepfake; direitos autorais e de imagem/voz; viés; alucinação; desatualização; exposição de dados. Mitigue com curadoria, anonimização, transparência, logs, checagem e supervisão.

USO SEGURO: IA apoia auditoria, segurança, jornalismo, Direito e setor público, mas não garante verdade, privacidade ou imparcialidade. Verifique, edite, valide, documente e responda pelo resultado.